

# Resumo Estendido - *Rethinking Multi-Interest Learning for Candidate Matching in Recommender Systems*

Rafael Carvalho

DEETC

ISEL

Lisboa, Portugal

a47663@alunos.isel.pt

**Abstract**—Este documento visa resumir de forma sintetizada e criteriosa as principais ideias expostas do artigo científico “*Rethinking Multi-Interest Learning for Candidate Matching in Recommender Systems*” escrito pelos autores Yueqi Xie, Jingqi Gao, Peilin Zhou, Qichen Ye, Yining Hua, Jae Boum Kim, procurando comprovar e atualizar algumas das referências do mesmo que sejam relevantes para a sua síntese.

Neste artigo, os autores mencionam os problemas existentes na aprendizagem de um modelo multi-interesse para construção de sistemas de recomendação (*Recommender Systems*) nomeadamente na fase de *Candidate Matching*, destacando o ênfase dado às arquiteturas do modelo, negligenciando os esquemas de treino. Como proposta de solução, sugerem a *framework* REMI, de fácil implementação, que pode ser aplicada a diversos métodos de *multi-interest candidate matching* já existentes, onde mostram fornecer resultados substancialmente melhores que métodos já estabelecidos sem introduzir maior exigência computacional.

**Index Terms**—resumo estendido, *recommender systems*, *multi-interest*, *candidate matching*

## I. INTRODUÇÃO

Muito utilizados nas plataformas de *e-commerce* para impulsionar as vendas, os sistemas de recomendação dividem-se em duas fases:

- 1) A **recuperação** de um sub-conjunto de itens de um *corpus* de itens,
- 2) O **ranking** de cada item com base na relevância, atendendo aos gostos do cliente.

Numa perspetiva de interesse em diversos conjuntos de itens (*multi-interest*), pretende-se representar os diversos gostos dos utilizadores com base nas interações com a plataforma.

Os modelos de aprendizagem *multi-interest* apresentam dois fatores que prejudicam a expressividade das representações multi-interesse, nomeadamente a falta de representações discriminativas causadas por um aumento expressivo nas amostras *easy negative* e o problema de *routing collapse*, onde apenas um item é considerado determinista para caracterizar o interesse, ao invés de um conjunto de itens semelhantes. Ambos os conceitos serão explicados em maior detalhe no capítulo que se segue.

No documento original, os autores destacam de forma sucinta os tópicos de *Candidate Matching*, *Multi-Interest*

*Learning*, e *Negative Sampling* em sistemas de recomendação, e apresentam alguns dos problemas em trabalho já desenvolvido. Como alternativa propõem a *framework* REMI, desenvolvida pelos autores, fundamentando e apresentando os resultados do seu algoritmo. Esta *framework* é sustentada sobre algoritmos de “*Interest-aware Hard Negative mining*” (IHN), e “*Routing Regularization*” (RR). Estes algoritmos procuram enfatizar a aprendizagem sobre amostras *Hard Negative* e introduzir uma forma de regularizar os termos nas matrizes “item-interesse”.

## II. FUNDAMENTAÇÃO TEÓRICA

### A. *Candidate Matching*

Entende-se por *candidate matching* o processo de filtragem de um *corpus* de itens de grande dimensão para recuperar um subconjunto menor, que desperte maior interesse do utilizador. Sendo uma etapa fundamental em sistemas de recomendação de larga escala, os modelos de *candidate matching* baseiam-se em arquiteturas simples, computacionalmente eficientes, permitindo uma recuperação de itens célere. Em simultâneo, durante a construção da representação de interesses de um utilizador, não consideram itens específicos, criando um perfil generalista de preferências reduzindo a complexidade uma vez que o modelo não necessita de ajustar aos potenciais itens recomendados ao utilizador.

Algumas soluções para *candidate matching* baseiam-se em *Collaborative Filtering* (CF) ou *Neural Collaborative Filtering* (NCF), que faz a correspondência de um utilizador com itens (*candidates*) com base em interações prévias introduzindo o conceito de *learnable matching* ao permitir que o algoritmo aprenda com interações passadas.

### B. *Multi-Interest Learning*

Mostrou-se, em investigações recentes [1], [2], que a modulação de interesses dos utilizadores num único vetor é insuficiente para capturar a complexidade dos padrões de interações. Desta forma, sistemas de recomendação mais recentes focam-se na captura dos vários interesses dos utilizadores em cápsulas, ou vetores de multi-interesse, registando também métricas como informação temporal e *clicks*.

Embora as arquiteturas para captura de multi-interesse sejam mais robustas e ricas em informação, apresentam-se ineficazes na fase de treino dadas as estratégias de amostragem negativa (*negative sampling*) e o problema de *routing collapse*.

### C. Negative Sampling

A amostragem negativa é crucial em sistemas de recomendação, ao permitir a seleção de um pequeno subconjunto de exemplos negativos ao invés de todo o conjunto de itens. Permite reduzir o custo computacional, acelerando a fase de treino sem prejudicar a aprendizagem do modelo.

Apresentam-se problemas quanto ao tipo de amostras negativas selecionadas durante a fase de treinos, uma vez que determinadas técnicas de amostragem produzem amostras consideradas fáceis (*easy negative*) ao modelo, não permitindo uma boa aprendizagem uma vez que não são particularmente desafiantes para que o modelo as distinga de amostras positivas.

Um item pode ser simultaneamente considerado *hard negative*, por exemplo, um computador, quando o tópico de interesse são produtos eletrônicos, e *easy negative* quando o tópico são alimentos. Trabalhos como [3] tentam mitigar este efeito ao introduzir uma técnica de amostragem baseada no conjunto de dados a ser processado e, em simultâneo, de todo o *corpus* de itens; no entanto falham ao selecionar *easy negatives*, compensando apenas na redução do *bias*. O método proposto na *framework* REMI foca no problema dos *hard negatives* com um custo negligenciável, ao re-atribuir o peso ao erro (*loss*) gerado pela amostragem uniforme.

## III. APRESENTAÇÃO DO PROBLEMA

Embora os avanços científicos feitos em Sistemas de Recomendação, as abordagens a problemas de multi-interesse têm limitações. Os modelos debatem-se com dificuldades no treino dada a abundância de amostras *easy negative* obtidas por técnicas de amostragem *softmax* uniforme, que falham em ser suficientemente desafiantes para a aprendizagem do modelo. Acrescenta-se também o problema do *routing collapse*, em que a representação de um determinado interesse torna-se demasiado restrita, focando-se em itens únicos ao invés de categorias mais abrangentes, diminuindo a eficiência do modelo.

Em cenários multi-interesse, cada utilizador possui um histórico de uma sequência de comportamentos, ordenado pela hora, e pretende-se que o modelo recupere o conjunto de itens do *corpus* que o cliente tenha mais probabilidade de interagir.

A arquitetura deste tipo de modelos codifica e atribui maior importância aos itens com os quais se interagiram, e de seguida constrói a matriz item-interesse (*routing matrix*). Na fase de treinos, seleciona-se o vetor mais relevante ao item considerado positivo, e modela-se o problema como uma tarefa de classificação, onde a probabilidade de um utilizador  $u$  com um interesse  $k$  interagir com um item positivo  $i^+$  pode ser representado com uma função *softmax*. Esta função reduz a complexidade computacional ao considerar apenas a classe positiva e as classes negativas amostradas, e produz bons

resultados em cenários de um único interesse, contudo mostra-se contraproducente em situações multi-interesse.

Com o objetivo de combater os problemas causados por *easy negatives* e *routing collapse*, propõem-se duas componentes que compõem a *framework* REMI:

- *Interest-aware Hard Negative Mining* (IHN)
- *Routing Regularization* (RR).

## IV. SOLUÇÃO PROPOSTA - Framework REMI

Com o objetivo de superar os desafios mencionados, propõe-se a *framework* REMI (**RE**thinking **M**ulti-**I**nterest **L**earning), implementada em Python, que pode ser aplicada a diversos métodos de aprendizagem em cenários multi-interesse sem que sejam necessárias alterações estruturais do modelo.

### A. Interest-aware Hard Negative Mining

Esta estratégia procura atenuar os problemas causados pelo aumento de amostras *easy negative* resultante de uma amostragem genérica *softmax*. Sem acrescentar *overhead* computacional, seguem-se dois princípios fundamentais para definir a estratégia de amostragem ideal:

- Uma amostra negativa é considerada informativa quando é mais propícia a levar o modelo a prever erradamente um item que considera pertencer ao interesse do utilizador. **Exemplo:** Para um modelo focado em compreender o interesse de um utilizador em filmes de comédia de família, uma amostra negativa pode ser uma comédia romântica. Isto porque são estilos de filmes semelhantes, levando o modelo a classificar erradamente. Estas classificações desafiantes são úteis na fase de treino ao permitir que o modelo distinga com maior precisão os interesses do utilizador.
- O nível de dificuldade na aprendizagem devem ser ajustável, uma vez que as amostras negativas informativas dependem do tamanho da amostra, e do conjunto de dados.

Propõe-se uma distribuição de amostras negativas subjetiva ao interesse, designando probabilidades maiores para amostras *hard negative*. Mede-se a semelhança entre o interesse e a codificação dos itens em vetores (*embeddings*) através do cálculo do produto interno. Um valor maior indica maior semelhança, e consequentemente um exemplo mais difícil de distinguir.

Face à grande dimensionalidade do conjunto de dados, propõe-se o uso de amostragem por importância baseado num método de Monte Carlo, aproximando a distribuição ideal com um menor custo computacional. Esta aproximação mostra-se vantajosa ao reduzir o *bias* e atribuir maior importância a amostras mais relevantes, neste caso, as *hard negatives*. De notar que para a fase de treino, as amostras *easy negatives* permanecem relevantes ao problema, sendo necessário arranjar um compromisso entre as amostras *hard negatives* e *easy negatives*. A dificuldade é ajustável pelo parâmetro  $\beta$  da *framework*, onde  $\beta = 0$  representa uma distribuição uniforme, e  $\beta \rightarrow \infty$  foca nas amostras negativas mais difíceis.

## B. Routing Regularization

Observou-se ao fim de algumas épocas de treino que o modelo aproximava o interesse a um único item, com base no histórico do utilizador, problema conhecido por *routing collapse*. Ao descobrir que o *routing collapse* é causado pela esparsidade da matriz de *routing* item-interesse, propôs-se o *routing regularization* como solução. Introduziu-se um termo de regularização nos pesos de *routing* baseado na norma de Frobenius da covariância das matrizes de *routing* dos vários interesses. Este termo garante que os pesos de *routing* têm variância suficiente e não são esparsos, levando a um *routing* de itens-interesse mais robusto e eficiente. Para um compromisso entre o erro causado pela amostragem e pelo termo de regularização, introduz-se um hiper-parâmetro  $\lambda$ .

## V. TESTES E DEMONSTRAÇÃO DE RESULTADOS

Para validação, realizaram-se cinco testes em três conjuntos de dados de larga escala:

- 1) **Amazon Books:** Contém interações com produtos da categoria "Livros" da plataforma Amazon
- 2) **Gowalla:** Uma rede social baseada em partilha de localizações
- 3) **RetailRocket:** Plataforma de *e-commerce* que inclui diversos tipos de interações de utilizadores num período de 4 meses.

Cada um destes conjuntos de dados apresenta características e desafios únicos para demonstração e validação de resultados em diferentes cenários.

Como pré-processamento removem-se os itens e utilizadores que ocorrem menos de cinco vezes nos conjuntos de dados, e consideram-se as interações como *feedback* implícito. Para a fase de treino e avaliação, o *dataset* é repartido em treino, validação e teste, num rácio de 8:1:1. Os testes comparam métricas como *Recall*, *Hit Rate* e *Normalized Discount Cumulative Gain* (NDGC) e são calculadas para os top 20 e top 50 itens recomendados.

Num panorama geral, observaram-se alguns problemas a nível computacional em modelos multi-interesse já conhecidos, onde o desempenho reduz significativamente com o aumento do conjunto de dados. A adoção da *framework* REMI apresenta melhorias de desempenho computacional, bem como melhores resultados para a três métricas mencionadas, para 20, e 50 itens. Para o primeiro e terceiro conjunto de dados, a REMI registou melhorias, em média, de 15% face a outros modelos de estado da arte, enquanto que para o conjunto de dados Gowalla a média de melhoria é de aproximadamente 7%.

Tratando-se de uma *framework* para a fase de treino, esta pode ser testada com modelos multi-interesse já existentes. Tomando como exemplo a *framework* ComiRec, o uso da REMI mostra melhorias entre **27.95% até 69.81%**, comprovando a sua compatibilidade com modelos já existentes, e as melhorias em termos de *performance*.

Num terceiro teste, compara-se a eficácia de diferentes estratégias de *negative sampling* no conjunto de dados *Amazon Books* para um *Recall* de 50 itens. Mostrou-se que a

técnica IHN implementada prevalece consistentemente perante outras técnicas de amostragem. Para amostragem com *Recall* semelhante, como uniforme e log-uniforme, observou-se que o intervalo de desempenho face ao IHN aumenta à medida que a dimensão da amostra decresce, mostrando potencial em tornar o treino mais eficiente com menos amostras negativas, sem comprometer a *performance*.

Para validação da *hardest negative sample*, tomou-se como amostra positiva um livro do tópico "Masculinidade e Fé" e observou-se que a amostra negativa mais difícil (*hardest negative*) é relacionada com "Espírito heroico", e a amostra negativa mais fácil com "Arte". Em simultâneo, quando a amostra positiva pertence ao tópico de "Política e Humanidade", em particular, o tópico de "Feminismo", as *hardest negative samples* também são relacionadas com "Política", mas não com "Feminismo". Isto demonstra a capacidade da granularidade da técnica, melhorando o desempenho do modelo.

Comparou-se a eficácia do algoritmo de *Routing Regularization* (RR) sem IHN comparativamente com outros métodos de regularização em cenários multi-interesse. Registaram-se melhorias significativas face a modelos sem qualquer regularização, **28.53%, 30.22%, e 47.11%** para os três conjuntos de dados, pela ordem pela qual foram apresentados. Face às outras técnicas, o *Routing Regularization* destaca-se como melhor para os três conjuntos de dados, com melhorias de **9.63%, 25.88%, e 31.19%** face ao Re4, segunda melhor técnica de regularização.

Finalmente, estudam-se os hiper-parâmetros da *framework*: O fator de concentração  $\beta$  e o de balanceamento  $\lambda$ . Comprovou-se que um aumento de  $\beta$  não produz necessariamente melhores resultados, e que o valor ideal para o fator de concentração varia entre *datasets*, justificado pelas características distintas de cada um, o que demonstra a importância de um  $\beta$  ajustável em diferentes cenários.

Já para o fator de balanceamento  $\lambda$ , registou-se que à medida que cresce, a *performance* aumenta, e só então torna a diminuir, o que comprova que a seleção deste parâmetro para evitar o *routing collapse* envolve o teste de diferentes valores.

## VI. CONCLUSÕES

Com foco à melhoria de desempenho de sistemas de recomendação, mais especificamente aos problemas associados ao aumento de amostras *easy negative* e *routing collapse*, propôs-se a *framework* REMI. Este trabalho mitiga o problema das amostras *easy negative*, que afetam a *performance* do modelo, ao implementar uma técnica de amostragem ideal baseada numa aproximação de um método Monte Carlo que foca em amostras *hard negative*, tornando a aprendizagem do modelo mais robusta e eficiente, ao usar como treino exemplos mais difíceis de distinguir. Em simultâneo, propõe-se a *Routing Regularization* para diminuir os problemas associados a *routing collapse*, onde um modelo estreita um tópico a um item. Este termo de regularização permite reduzir a esparsidade da matriz de *routing* item-interesse, aumentando a eficiência durante o treino.

Em cinco testes, a REMI mostrou melhorias significativas face a modelos multi-interesse de estado da arte, e tratando-se de uma *framework* focada no esquema de treino, comprovou-se de que forma permite melhorar o desempenho de modelos já existentes sem introdução de *overhead* computacional. Esta *framework* introduz dois hiper-parâmetros,  $\beta$ , fator de concentração, e  $\lambda$ , fator de balanceamento. O primeiro permite ajustar o nível de dificuldade das amostras negativas a serem fornecidas ao modelo durante a fase de treino, e compreendeu-se que o desempenho deste parâmetro varia face às características do conjunto de dados a ser tratado. Para o fator de balanceamento,  $\lambda$ , este permite ajustar a regularização da matriz item-interesse, sendo que a escolha do seu valor deve ser considerado após vários testes e comparação.

Perspetiva-se que no futuro esta *framework* de treino, implementada em Python, possa contribuir para a investigação de sistemas de recomendação multi-interesse, e enaltecer a importância da exploração de diferentes métodos de treino para melhoria do desempenho dos modelos.

#### REFERENCES

- [1] Chao Li, Zhiyuan Liu, Mengmeng Wu, Yuchi Xu, Huan Zhao, Pipei Huang, Guoliang Kang, Qiwei Chen, Wei Li, and Dik Lun Lee. 2019. Multi-interest network with dynamic routing for recommendation at Tmall. In CIKM. 2615– 2623.
- [2] Yukuo Cen, Jianwei Zhang, Xu Zou, Chang Zhou, Hongxia Yang, and Jie Tang. 2020. Controllable multi-interest framework for recommendation. In SIGKDD. 2942–2951.
- [3] Ji Yang, Xinyang Yi, Derek Zhiyuan Cheng, Lichan Hong, Yang Li, Simon Xiaoming Wang, Taibai Xu, and Ed H Chi. 2020. Mixed negative sampling for learning two-tower neural networks in recommendations. In Companion Proceedings of the Web Conference 2020. 441–447.